Tässä harjoituksessa käytän tilastotieteen perusmenetelmiä sekä ohjaamattoman oppimisen menetelmiä annetun datan kuvailuun ja analyysiin. Työn tarkoituksena on valmistella data analyysiä varten, tehdä analyysi datalle, vastata tutkimuskysymyksiin sekä esittää yhteenveto analyysistä. Tehtävänannossa on kaksi tutkimuskysymystä. Ensimmäinen tutkimuskysymys on kuka biologeista luokittelu puut parhaiten. Toinen tutkimuskysymys on tunnistaa datasta parhaiten luokittelevat attribuutit.

1 Datan kuvailu ja preprosessointi

Aloitetaan datan yleisellä kuvailulla. Datasetissä on 300 riviä dataa ja 11 saraketta muuttujia. Sarakkeet voidaan jakaa kolmeen kategoriaan. Numeerisia muuttujia on 7, kategorisia muuttujia on 2 ja tutkijoihin liittyviä muuttujia on 2. Datasetissä ei ole puuttuvia arvoja, mutta duplikaattiarvoja on 20 kappaletta.

Käytetään numeerisia ja kategorisia muuttujia analyysiin ja klusterointiin. Verrataan klusterointia tutkijoiden luokitteluun, jonka avulla voidaan arvioida ovatko tutkijat onnistuneet puiden luokittelussa. Käytetään numeerisia ja kategorisia muuttujia selvittämään mitkä muuttujat ovat enemmän ja mitkä vähemmän informatiivisia, jotta jatkossa voidaan vähentää turhan datan keruuta.

Numeeriset muuttujat saavat seuraavia tilastollisia arvoja

	length	diameter	cones	leaves	bark_thickness	seed_size	soil_pH
count	300.00	300.00	300.00	300.00	300.00	300.00	300.00
mean	267.45	115.53	87.84	10689.06	1.16	1.00	7.99
std	78.86	24.84	58.51	5691.38	0.27	0.02	1.04
min	69.08	73.96	-10.00	1067.00	0.62	0.83	4.85
25%	207.40	98.31	35.75	5720.00	0.98	1.00	7.32
50%	289.56	105.57	85.50	10631.00	1.09	1.00	8.02
75%	306.41	130.83	131.25	15620.50	1.31	1.00	8.63
max	516.90	214.82	199.00	19956.00	2.25	1.16	11.85

Taulukosta nähdään seuraavat tilastolliset arvot lukumäärä, keskiarvo, keskihajonta, pienin ja suurin arvo sekä kvartaalit Q1, Q2 ja Q3. Näiden tilastojen vertaus toisiinsa ei ole mielekästä tässä vaiheessa, koska muuttujan skaala vaikuttaa näiden arvojen suuruuteen. Ainoa poikkeava arvo on käpyjen pienin lukumäärä, joka on -10. Tämä ei ole mahdollista, joten korjataan tilanne. Oletetaan, että negatiivinen etuliite on näppäilyvirhe ja otetaan jokaisen kävyn itseisarvo ja asetetaan se jokaisen rivin arvoksi tässä sarakkeessa.

Tarkastellaan numeeristen muuttujien laatikkokuvaajia

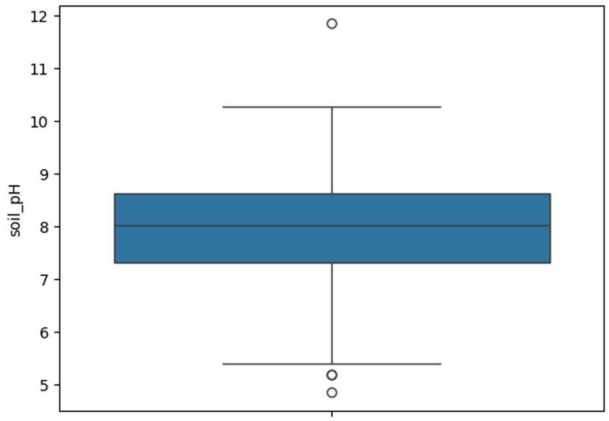

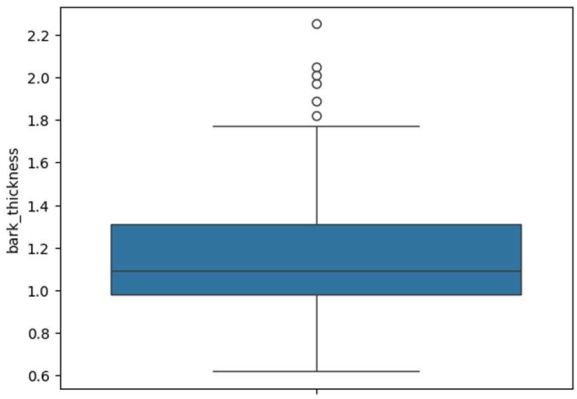

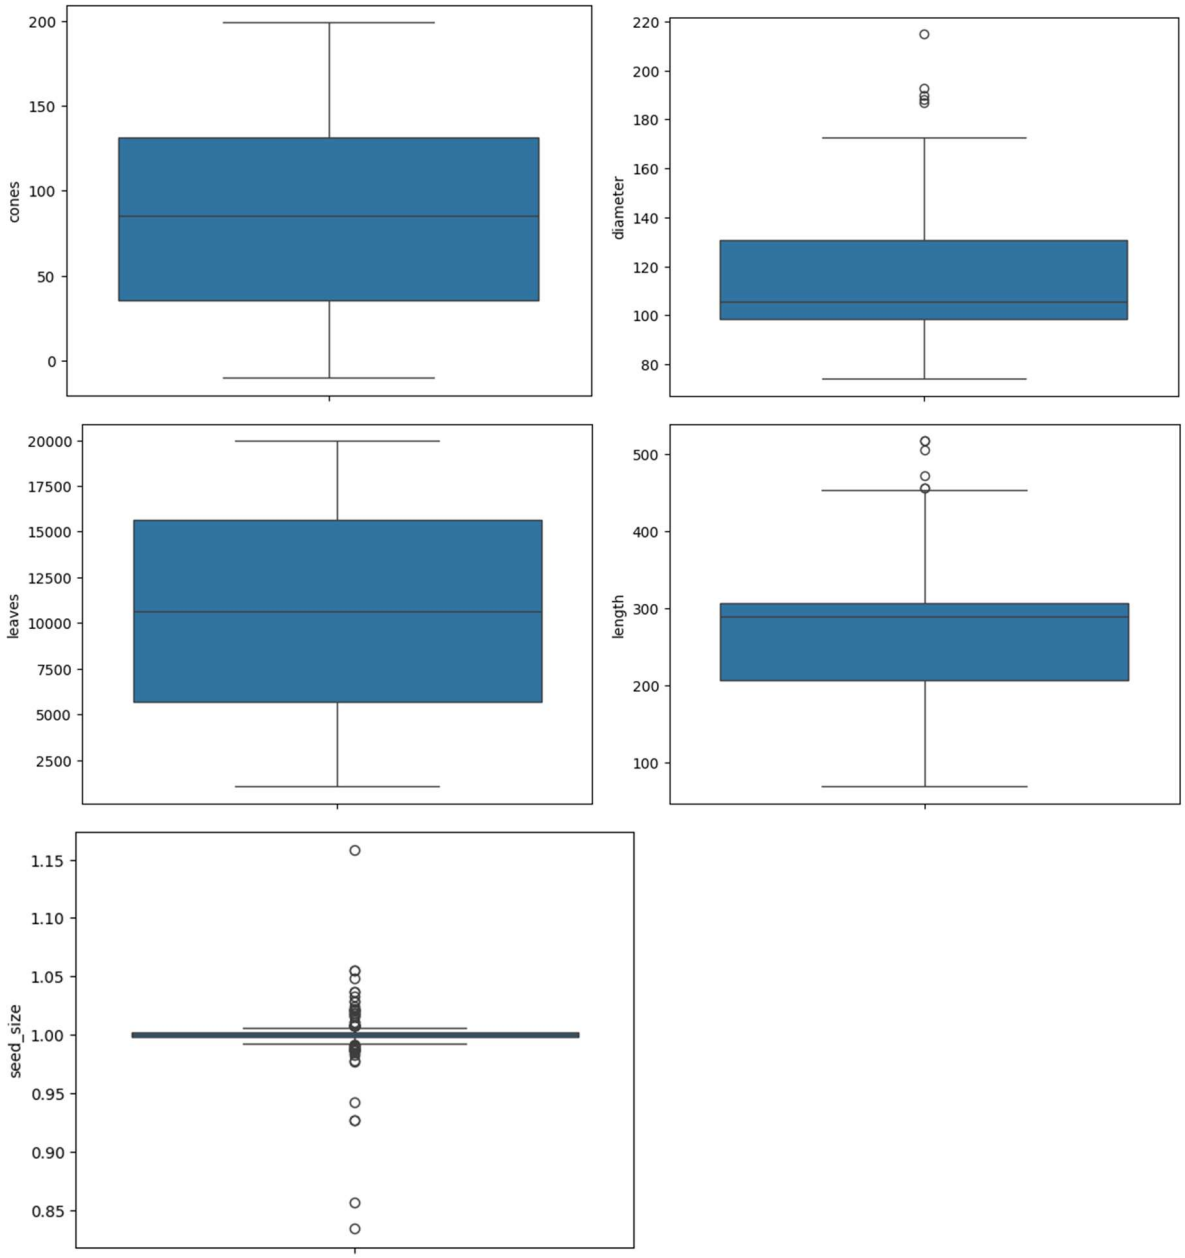

Kuvaajista huomataan kaikkien arvojen olevan lähes symmetrisesti jakautuneita. Suurimpia poikkeavia arvoja saadaan siemenen koolla, joka saa suurimman osan arvoistaan hyvin kapealta väliltä, mutta jossa on myös paljon poikkeavia arvoja.

Kategorisille muuttujille voidaan myös laskea attribuutteja.

	fungi_present	color_guess
count	300	300
unique	2	5
top	False	lightish
freq	154	76

Kuvan taulukosta nähdään seuraavat tilastot lukumäärä, uniikkien luokkien lukumäärä, moodi ja moodin taajuus. Sienien olemassaolon kategoria on lähes symmetrisesti jakautunut kahteen, mutta värin kategorioiden jakaumaa ei vielä saa selville tästä. Käytetään ristitaulukkoa eri kategoristen arvojen esiintymisen listaukseen.

```
fungi_present  color_guess
False          mid-green      41
               lightish       39
True           lightish       37
False          dark           34
True           light          31
               mid-green      29
               dark           27
False          light          26
True           darkish        22
False          darkish        14
Name: count, dtype: int64
```

Taulukosta nähdään, että kaikkia yhdistelmiä kategorisia arvoja on olemassa datasetissä, joten joidenkin yhdistelmien puuttumista ei tarvitse ottaa huomioon jatkoanalyysissä.

Seuraavaksi tutkitaan, ovatko numeeriset muuttujat normaalisti jakautuneita. Normaalisti jakautuneet muuttujat eivät sovellu suoraan ohjaamattomaan oppimiseen, koska niiden tasaisen jakauman vuoksi niistä ei voi muodostaa selviä alueita helposti. Lisäksi tilastollisten testien valinta edellyttää tietoa datan normaalijakautuneisuudesta. Käytetään Shapiro-Wilkin normaalisuustestiä numeerisiin muuttujiin.

```
P-arvot numeeriselle datalle:
length          1.42e-07 < 0.05
diameter        1.86e-14 < 0.05
cones           3.04e-08 < 0.05
leaves          1.04e-08 < 0.05
bark_thickness  5.77e-09 < 0.05
seed_size       2.18e-28 < 0.05
soil_pH         0.442    > 0.05
```

Huomataan, että maan ph on normaalisti jakautunut, joten sitä ei käytetä lopullisen muuttujavektorin muuttujissa. Muut arvot eivät ole normaalisti jakautuneita, joka auttaa ohjaamattomassa oppimisessa.

Lasketaan numeeristen muuttujien korrelaatiokertoimet Spearmanin järjestyskorrelaatiokertoimen avulla. Valitaan järjestyskorrelaatio, koska muuttujat eivät ole normaalisti jakautuneita. Testin tuloksista havaitaan, kuinka paljon yhteisvaihtelua muuttujilla

on. Vahvasti korreloituneet muuttujat sisältävät paljon samaa tietoa, joka voi heikentää ohjaamattoman oppimisen tuloksia.

```
length          vs seed_size : r=-0.00, p=0.9542
length          vs soil_pH   : r=-0.05, p=0.4230
diameter        vs length    : r=0.18 , p=0.0024
diameter        vs leaves    : r=-0.00, p=0.9361
diameter        vs seed_size : r=-0.05, p=0.3646
diameter        vs soil_pH   : r=-0.04, p=0.4772
cones           vs length    : r=0.05 , p=0.4133
cones           vs diameter  : r=0.07 , p=0.2427
cones           vs leaves    : r=0.04 , p=0.5169
cones           vs seed_size : r=0.07 , p=0.2380
cones           vs soil_pH   : r=0.07 , p=0.2462
leaves          vs length    : r=-0.07, p=0.2332
leaves          vs seed_size : r=-0.10, p=0.1068
leaves          vs soil_pH   : r=0.01 , p=0.8883
bark_thickness  vs length    : r=0.16 , p=0.0059
bark_thickness  vs diameter  : r=0.86 , p=0.0000
bark_thickness  vs cones     : r=0.05 , p=0.3614
bark_thickness  vs leaves    : r=0.03 , p=0.6566
bark_thickness  vs seed_size : r=-0.10, p=0.0797
bark_thickness  vs soil_pH   : r=0.00 , p=0.9409
seed_size       vs soil_pH   : r=0.02 , p=0.6952
```

Taulukosta nähdään seuraavien muuttujien olevan korreloituneita toistensa kanssa. Halkaisija-pituus, kaarna-pituus ja kaarna-halkaisija. Huomataan näiden kolmen muuttujan olevan korreloituneita toistensa kanssa, joten muuttujavektorissa tulee olla vain yksi näistä samaan aikaan.

Lasketaan seuraavaksi kategoristen muuttujien korrelaation Khiin neliö -testillä.

```
color_guess     vs fungi_present  : chi2=3.77 , p=0.4385
```

Värin ja sienien välillä ei ole vahvaa korrelaatiota.

Lopuksi suoritetaan varianssianalyysi Kruskal-Wallis-testillä, koska data ei ole normaalisti jakautunutta sekä siinä on kategorisia muuttujia. Tämän testin tuloksena saadaan tietää, onko kahden eri muuttujan varianssien ero merkittävä vai ei. Jos varianssit ovat merkittäviä, halutaan molemmat muuttujavektoriin, koska eri suuret muuttujien väliset varianssit tuottavat parempia klustereita.

numeric	categorical	H_stat	p_value	significant
diameter	fungi_present	14.0574	0.0002	Yes
bark_thickness	fungi_present	12.4700	0.0004	Yes
bark_thickness	color_guess	8.1484	0.0863	No
seed_size	fungi_present	1.2201	0.2693	No
length	fungi_present	0.9730	0.3239	No
seed_size	color_guess	4.5791	0.3333	No
soil_pH	color_guess	3.6749	0.4518	No
cones	color_guess	3.6287	0.4586	No
diameter	color_guess	2.7884	0.5938	No
length	color_guess	2.2875	0.6830	No
cones	fungi_present	0.1440	0.7043	No
soil_pH	fungi_present	0.0576	0.8104	No
leaves	color_guess	0.9785	0.9130	No
leaves	fungi_present	0.0001	0.9935	No

Taulukosta nähdään kahden muuttujan yhdistelmän olevan tilastollisesti merkittävää. Nämä yhdistelmät ovat halkaisija-sieni ja kaarna-sieni. Muuttujavektoria rakentaessa halutaan ottaa huomioon ainakin nämä yhdistelmät.

Lopputuloksena datasta on löytynyt muuttujia, jotka sopivat paremmin ja huonommin ohjaamattomaan oppimiseen. Esimerkiksi maan ph-arvoa ei käytetä ohjaamattomassa oppimisessa sen normaalijakautuneisuuden vuoksi sekä vahvasti korreloituneita muuttujia ei käytetä toistensa kanssa.

2 Datan klusterointi ja analyysi

Datan analyysissä tarkoituksena on käyttää ohjaamattoman oppimisen menetelmiä luokittelemaan annetut puut. Puiden luokittelua verrataan sitten tutkijoiden antamiin luokitelmiin, josta selvitetään ovatko tutkijat onnistuneet puiden luokittelussa.

Ohjaamattomassa oppimisessa on tärkeää muodostaa ominaisuusvektori, jonka avulla klusterointia voidaan tehdä. Tähän ominaisuusvektoriin valitaan muuttujia, joilla on pieni yhteinen korrelaatio ja suuri muuttujien välinen ero. Näin saadaan valittua muuttujat, jotka kuvaavat mahdollisimman hyvin merkittäviä ominaisuuksia ja poistetaan ylimääräistä dataa, joka johtaa ohjaamattomassa oppimisessa helposti huonoihin tuloksiin.

Edellisten tilastollisten testien perusteella tiedetään, että pituudella, halkaisijalla ja kaarnan paksuudella on suuri korrelaatio toistensa kanssa. Valitaan toinen ominaisuus kategorisista muuttujista. Valitaan kolmas ominaisuus jäljelle jääneistä ei normaalisti jakautuneista muuttujista.

```
feature_1 = ['length', 'diameter', 'bark_thickness']
feature_2 = ['fungi_present', 'color_guess']
feature_3 = ['cones', 'leaves', 'seed_size']
```

Kaikkien näiden muuttujien yhdistelmistä muodostuu lista ominaisuusvektoreita, joissa on kaikissa kolme uniikkia yhdistelmää näitä kolmea ominaisuutta.

Koska ominaisuudet ovat numeerisia ja kategorisia käytetään Gower-etäisyyttä, joka toimii numeerisille ja kategorisille muuttujille. Gower-etäisyys tuottaa matriisin, jossa yksittäisten datakenttien arvot ovat Gower-etäisyyden tuloksia, jossa pienempi arvo viittaa suurempaan yhtäläisyyteen.

Gower-etäisyyttä ei voi käyttää suoraan kaikkien klusterointimenetelmien kanssa, joten valitaan yhteensopiva menetelmä tämän perusteella. Hierarchical Density-Based Spatial Clustering of Applications with Noise on klusterointialgoritmi, jonka avulla luokitellaan samanlaisia pisteitä. Hdbscan toimii datalla, jossa on poikkeavia arvoja ja se valitsee parhaan klusteroinnin useasta parametristä hierarkkisesti, joten sen kouluttaminen on helpompaa kuin dbscan-klusteroinnin. Tärkein ominaisuus tässä tilanteessa on sen kyky käyttää Gower-etäisyyttä natiivisti.

```
cluster_sizes = [2, 3, 4, 5]
sample_range = [1, 2, 3]
```

Koulutetaan hdbscan eri kokoisilla klustereilla ja eri toleransseilla poikkeaviin arvoihin. Klusterin koon valinta vaikuttaa hdbscan: iin merkittävästi ja sample_range kertoo, kuinka herkkä menetelmä on poikkeaville arvoille.

```
                                features   method  min_cluster_size  \
107  (diameter, fungi_present, seed_size)  hdbscan                 5

     min_samples  n_clusters  n_noise  \
107            3           3        4

                                                 labels  silhouette
107  [1, 2, 1, 0, 0, 0, 1, 2, 1, 0, 0, 0, 2, 0, 0, ...      0.7544
```

Tuloksena parhaan siluettiarvon saa halkaisija, sienien läheisyys ja siemenen koon muuttujista koostuva ominaisuusvektori. Klustereita on kolme ja poikkeavia arvoja on 4, joka on hyvä tulos tälle menetelmälle. Tarkastellaan tulosta kahdella eri ulottuvuuden rajoittavalla projektiolla. Ensimmäinen näistä on multidimensional scaling, joka pyrkii säilyttämään datapisteiden globaalit etäisyydet. Toinen tekniikka on T-distributed stochastic neighbor embedding, joka pyrkii säilyttämään datapisteiden lokaalit etäisyydet.

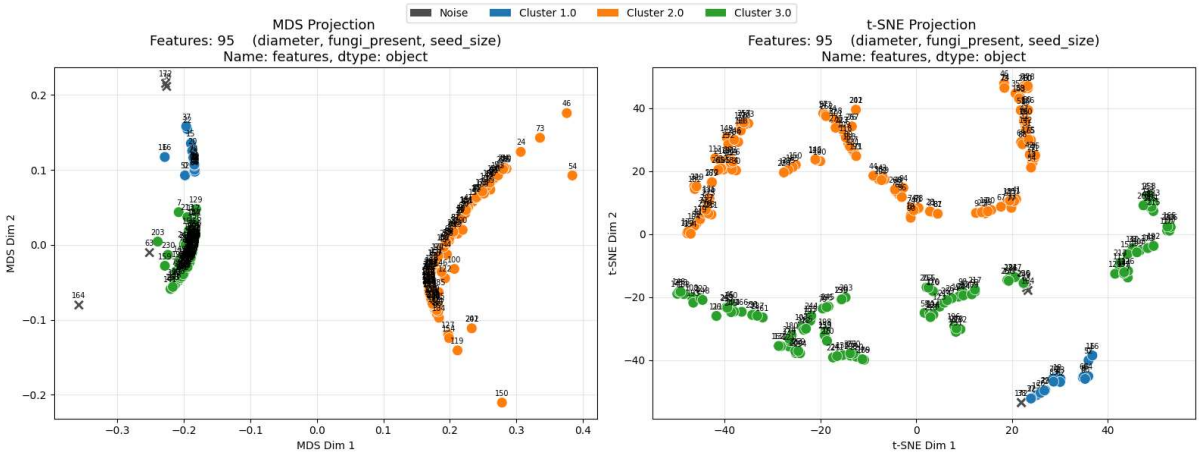

Kuvasta nähdään visuaalisesti kaksi eri tapaa projektoida korkeaulotteinen data kahteen ulottuvuuteen ja pisteiden väritys saatiin hdbscan-menetelmällä. Huomataan värityksen sopivan melko hyvin klustereihin, joka kertoo klusteroinnin onnistumisesta.

Seuraavaksi sovitetaan hdbscan-menetelmät tuottamat arvaukset biologien arvauksiin. Ongelmana on, että biologien arvaukset ja klusteroinnin tuottamat arvaukset eivät välttämättä ole kuvattu samoilla numeroilla. Pitää selvittää mitkä tutkijoiden arvaukset sopivat parhaiten klusteroinnin arvauksiin. Käytetään tähän unkarilaista algoritmia sekä ristitaulukkoa.

```
Unique labels A: [1. 2. 3.]
Unique labels B: [0 1 2]

Contingency matrix:
[[55 14 13]
 [56  6 48]
 [25  0 59]]
```

Ristitaulukosta nähdään mitkä luokat ovat yhteydessä toisiinsa. Jokaisesta sarakkeesta valitaan suurin arvo, jonka avulla saadaan suurin sopivuus. Tästä taulukosta saadaan seuraava muutos 0 → 2., 1 → 1., 2 → 3. Tämä tuottaa parhaan mahdollisen sovituksen näiden luokittelujen välillä, joka on 46,74 %. Tämän muutoksen avulla tutkijoiden ja klusteroinnin arvaukset ovat verrattavissa toisiinsa.

Sovitetaan tutkijoiden arvaukset klustereihin.

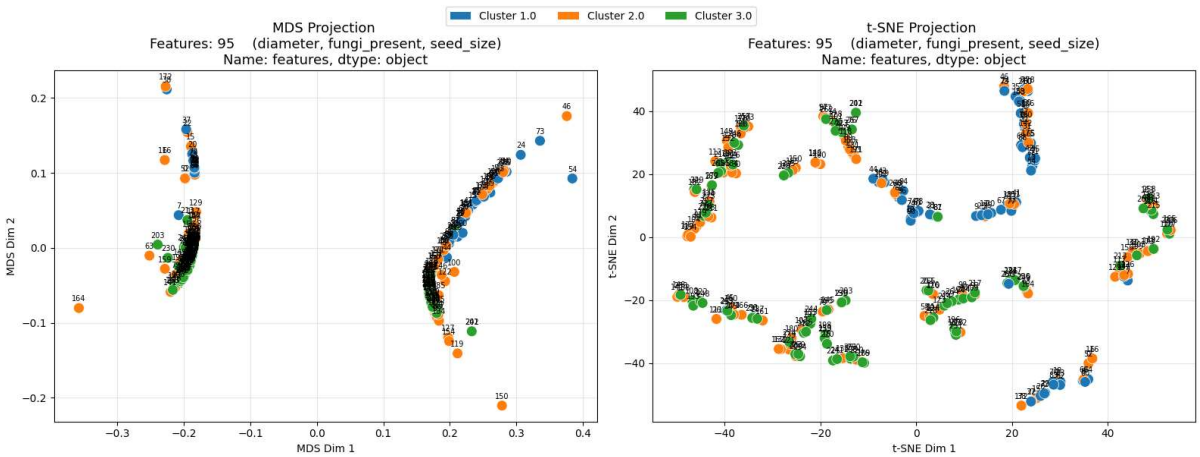

Huomataan jonkin verran yhtäläisyyksiä, mutta moni luokittelu on silti eri kuin klusteroinnissa. Lasketaan tutkijoiden arvauksille seuraavat tilastot tosien arvausten määrä, accuracy ja recall. Accuracy on oikein luokiteltujen määrän suhde kaikkiin luokitteluihin ja recall on oikein luokiteltujen suhde oikein ja väärin luokiteltuihin. Tässä tapauksessa puun väärin luokittelu ei ole vakavaa, joten annetaan suurempi painoarvo accuracylle.

	collector_id	total_samples	correct	accuracy	recall
2	3.0	90.0	47.0	0.522222	0.522222
0	1.0	100.0	44.0	0.440000	0.440000
1	2.0	90.0	38.0	0.422222	0.422222

Kuvasta huomataan kaikkien biologien tunnistavan puita paremmin kuin arvaamalla satunnaisesti. Jos oletetaan, että luokkia on vain kolme, oikea arvaus tulee todennäköisyydellä 33 % ja kaikkien biologien tarkkuus oli tätä suurempaa. Tarkin biologi on 3, 52 % tarkkuudella ja epätarkin on biologi 2, 42 % tarkkuudella.

3 Loppupäätelmät

Ensimmäinen tutkimuskysymys on, kuka biologeista luokitteli puut parhaiten. Perustuen klusterointiin ja parhaaseen mahdolliseen sovitukseen biologien luokkien ja klusteroinnin luokkien välillä, biologi 3 on paras luokittelemaan puita näiden tilastojen perusteella.

Toinen tutkimuskysymys on, mitkä muuttujat luokittelevat datan parhaiten. Perustuen tilastollisiin menetelmiin, voidaan sanoa parhaiksi muuttujiksi halkaisijan, pituuden, kaarnan paksuuden ja sienien läheisyyden. Tämä perustuu Kruskal-Wallis-testin tuloksiin. Heikoin muuttuja on maan ph-arvo, koska se on normaalisti jakautunut.

Nämä johtopäätökset pitävät melko hyvin paikkaansa klusteroinnin tuloksissa, joissa parhaan tuloksen sai halkaisija, sienien läheisyys ja siemenen koko. Mutta maan ph-arvo saa myös hyviä klusterointituloksia kaarnan paksuuden ja sienien läheisyyden kanssa.

	features	method	silhouette
119	(diameter, fungi_present, seed_size)	hdbscan	0.7544
118	(diameter, fungi_present, seed_size)	hdbscan	0.7522
117	(diameter, fungi_present, seed_size)	hdbscan	0.7522
239	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
230	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
237	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
238	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
236	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
233	(bark_thickness, fungi_present, soil_pH)	hdbscan	0.7491
45	(length, fungi_present, soil_pH)	hdbscan	0.7430

Toiset muuttujat saavat puolestaan paljon huonoja klusterointituloksia.

	features	method	silhouette
131	(diameter, fungi_present, leaves)	hdbscan	0.3384
74	(length, color_guess, leaves)	hdbscan	0.4402
102	(diameter, fungi_present, cones)	hdbscan	0.4435
121	(diameter, fungi_present, leaves)	hdbscan	0.4442
222	(bark_thickness, fungi_present, leaves)	hdbscan	0.4565
266	(bark_thickness, color_guess, leaves)	hdbscan	0.4573
80	(length, color_guess, leaves)	hdbscan	0.4574
127	(diameter, fungi_present, leaves)	hdbscan	0.4621
77	(length, color_guess, leaves)	hdbscan	0.4632
225	(bark_thickness, fungi_present, leaves)	hdbscan	0.4667

Perustuen klusterointituloksiin, lehtien ja käpyjen määrä tuottavat huonoja klusterointituloksia.

Lopullinen päätelmä on siis, että lehtien määrä ja käpyjen määrä tuottavat huonoja klusterointituloksia, joten niiden kerääminen ei ole kannattavaa biologeille. Tämä käy myös intuitiivisesti järkeen, koska lehtien ja käpyjen laskeminen on haastavaa, jos ympäristöä ei ole kontrolloitu.